

보스 레이드 환경에서 행동 트리와 역할별 강화학습을 결합한

2계층 하이브리드 협동 NPC:

전투 의사결정과 기믹 수행의 분리 학습

박준형

메타버스 테크놀로지, 서강대학교 가상융합전문대학원

초록

다중 사용자 온라인 게임의 보스 레이드는 역할이 구분된 파티원 간의 긴밀한 협동을 요구하지만, 파티원 NPC를 규칙 기반으로 구현하면 상황 적응력이 떨어지고, 강화학습만으로 구현하면 실패 시 즉시 전멸로 이어지는 희소한 협동 기믹을 안정적으로 학습하지 못한다. 본 연구는 저자의 사전 실험에서 순수 강화학습 정책이 약 30만 에피소드의 학습에도 불구하고 기믹 수행에 실패한 관찰을 동기로, 의사결정을 두 계층으로 분리한 하이브리드 구조를 제안한다. 제1계층은 결정론적 행동 트리(behavior tree)로서 전멸기 은신, 임박 위험 회피, 낙인 산개 등 이산적이고 규칙이 명확한 기믹을 확정적으로 처리하고, 제2계층은 역할별(탱커·힐러·서포터) 독립 PPO 정책으로서 포지셔닝, 어그로 관리, 회복 대상 선택과 같은 연속적 전투 판단을 담당한다. 기믹 보상을 제거한 순수 전투 보상, 행동 트리가 발화한 턴을 학습 표본에서 제외하는 준마르코프 귀속, 보스 체력 3단계 커리큘럼, 행동 복제 초기화, 그리고 플레이어 성향(공격형·안정형·미숙형) 도메인 랜덤화를 결합하여 20,000 에피소드를 학습하였다. Unity 기반 실시간 클라이언트와 Python 시뮬레이션 서버로 구성된 자체 제작 보스 레이드 게임에서, 제안 구조는 기믹 성공률

87%를 유지하면서 최종 난이도 보스에 대해 승률 70.8%(120 에피소드 평가)를 기록하여 규칙 기반 기준 정책(64-75%)과 동등한 수준에 도달하였다. 이때 규칙 계층이 결정한 턴은 전체의 약 22%에 그쳐, 행동의 대부분은 학습 정책이 담당하는 분업이 성립하였다. 본 초안은 연구의 설계와 학습 결과를 보고하며, 실제 플레이어 대상 사용성 평가를 향후 과제로 제시한다.

주요어: 다중 에이전트 강화학습, 행동 트리, 하이브리드 게임 AI, 협동 NPC, 보스 레이드, PPO

1. 서론

MMORPG의 보스 레이드는 탱커, 딜러, 힐러와 같이 역할이 구분된 파티원이 보스의 공격 패턴에 실시간으로 대응하며 협동해야 하는 콘텐츠이다. 파티원의 일부 또는 전부를 NPC로 대체하려는 수요는 꾸준히 존재하지만 — 예컨대 파티 매칭이 어려운 시간대의 솔로 플레이 지원이나 싱글 플레이어 게임에서의 동료 시스템 — 상용 게임의 동료 NPC는 대부분 유한 상태 기계(finite state machine, FSM)나 행동 트리(behavior tree, BT)와 같은 규칙 기반 기법으로 구현된다(Isla, 2005). 규칙 기반 NPC는 동작이 예측 가능하고 필수 행동을 강제할 수 있다는 장점이 있으나, 설계자가 명시하지 않은 상황 — 파티원 조합의 변화, 플레이어의 실수, 패턴의 중첩 — 에서 경직된 행동을 보이며, 행동 규칙이 복잡해질수록 유지 보수 비용이 급격히 증가한다.

강화학습(reinforcement learning, RL)은 이러한 경직성을 극복할 대안으로 주목받아 왔다. 대규모 학습을 통해 StarCraft II(Vinyals et al., 2019)와 Dota 2(Berner et al., 2019)에서 인간 최상위권 수준의 협동 플레이가 달성되었고, 팀 기반 일인칭 게임에서 인간과 함께 플레이할 수 있는 수준의 에이전트도 보고되었다(Jaderberg et al., 2019). 그러나 보스 레이드 환경에 순수 강화학습을 적용할 때는 이들 연구와 구별되는 구조적 난점이 있다. 보스 레이드의 협동 기믹 — 예컨대 특정 시점에 전원이 엄폐물 뒤로 숨어야 하는 전멸기 — 는 (a) 발생 빈도가 낮아 학습 신호가 희소하고, (b) 파티원 전원의 동시 성공을 요구하며, (c) 단 한 번의 실패가 즉시 에피소드 종료 (전멸)로 이어진다. 탐험 과정의 확률적 정책이 이러한 조건을 유연히 만족하기는 어렵고, 실패가 반복되면 기믹 구간 이전의 전투 행동까지 부정확한 귀인으로 오염된다.

이 난점은 이론적 우려에 그치지 않는다. 저자는 본 연구에 앞서 동일 계열의 보스 전투 환경에서 순수 PPO(Schulman et al., 2017) 기반 역할별 정책을 약 30만 에피소드 학습시키는 사전 실험을 수행하였는데, 전투 승률은 일정 수준에서 정체되었고 특히 협동 기믹의 수행은 학습 후반까지 안정화되지 않았다. 나아가 약 16만 에피소드 이후 정책 엔트로피가 붕괴하면서 성능이 오히려 퇴행하는 현상도 관찰되었다. 보상 설계를 바꾸어 가며 반복한 실험들에서 공통적으로 확인된 것은, 기믹 수행과 전투 판단이라는 성격이 다른 두 과제를 단일 정책의 단일 보상 신호로 동시에 학습시키는 접근 자체의 비효율이

었다.

본 연구는 이 관찰로부터 출발하여, 두 과제를 서로 다른 계층에 명시적으로 분리하는 2계층 하이브리드 구조를 제안한다. 핵심 설계 원칙은 “이산적이고 규칙이 명확한 행동은 규칙으로, 연속적이고 맥락 의존적인 판단은 학습으로”이다. 제1계층은 결정론적 BT로서 전멸기 은신, 임박한 광역기 회피, 낙인 산개와 같은 기믹을 우선순위 규칙으로 확정 처리하고, 규칙에 해당하지 않는 턴은 제2계층으로 위임한다. 제2계층은 역할별로 독립된 PPO 정책으로서 포지셔닝, 공격 타이밍, 어그로 관리, 회복 대상 선택과 같은 전투 판단을 담당한다. 기믹이 제1계층에서 보장되므로 제2계층의 보상에서 기믹 항을 제거할 수 있고, 이는 학습 공간의 축소와 보상 신호의 명료화로 이어진다.

제안 구조는 Unity 기반 실시간 클라이언트와 Python 시뮬레이션 서버로 구성된 자체 제작 보스 레이드 게임에 구현되었다. 환경은 11종의 보스 패턴(방향성 근접기, 광역기, 추격 돌진, 카운터 유도기, 패링 유도기, 전멸기 등), 상시 무력화 게이지, 보스 체력에 연동되어 축소되는 원형 전장을 포함하며, 실제 플레이어 1인(딜러)과 NPC 3인(탱커, 힐러, 서포터)이 한 파티를 이룬다. 본 초안은 진행 중인 연구의 시스템 설계, 학습 방법, 그리고 학습 중간 시점의 결과를 보고한다.

본 연구의 기여는 다음과 같이 요약된다. 첫째, 보스 레이드의 협동 기믹과 전투 판단을 BT와 역할별 RL로 분리하는 2계층 하이브리드 의사결정 구조를 제안하고, 실제 플레이 가능한 게임에 구현하였다. 둘째, 제1계층이 발화한 턴을 학습 표본에서 제외하고 해당 구간의 보상을 직전 학습 결정에 귀속시키는 준마르코프(semi-Markov) 표본 수집 방식으로, 규칙 개입이 정책 경사 추정을 오염시키는 문제를 다루었다. 셋째, 실제 플레이어와의 협동을 전제로 하는 환경 특성을 반영하여, 학습 중 플레이어 모델의 성향(공격형·안정형·미숙형)을 에피소드마다 랜덤화하는 도메인 랜덤화(Tobin et al., 2017)를 적용하였다. 넷째, 순수 강화학습 사전 실험의 실패 관찰을 포함한 설계 근거와 학습 중간 지표(기믹 성공률, 계층별 발화 비율, 성향별 승률)를 보고하여, 동일 문제를 다루는 후속 연구의 기준점을 제공한다.

2. 관련 연구

2.1 게임 NPC의 규칙 기반 제어

FSM과 BT는 상용 게임 AI의 표준적 기법이다. 특히 BT는 우선순위가 있는 조건-행동 규칙을 트리로 구조화하여 복잡한 행동의 조합과 재사용을 용이하게 하며, Halo 2 이후 다수의 상용 게임에서 채택되었다(Isla, 2005). 규칙 기반 제어의 강점은 결정론적 보장이다. 즉 특정 조건에서 특정 행동이 반드시 수행됨을 설계 시점에 확정할 수 있다. 본 연구는 이 강점을 폐기하지 않고, 실패 비용이 극단적인 기믹 구간에 한정하여 활용한다.

2.2 다중 에이전트 강화학습과 역할

다중 에이전트 강화학습(MARL)에서는 중앙 집중 학습-분산 실행 패러다임 하에 가치 분해(Rashid et al., 2018)나 중앙 비평가(Lowe et al., 2017)를 통해 협동 행동을 학습하는 접근이 주류를 이룬다. 역할의 관점에서는, 에이전트를 역할 공간에 분화시켜 탐색을 구조화하는 ROMA(Wang et al., 2020)와 같이 역할을 학습의 산물로 창발시키는 연구가 있다. 반면 본 연구의 대상인 보스 레이드는 탱커·힐러·서포터라는 역할이 게임 규칙(스킬 구성, 능력치)으로 사전에 고정되어 있으므로, 역할을 창발시키는 대신 역할별로 독립된 관측·정책·보상을 부여하는 명시적 역할 분리를 채택한다. 이는 각 역할의 행동 공간에서 불가능한 행동(예: 탱커의 회복)을 제거하고 보상 신호를 역할 목적에 정렬시키는 실용적 이점이 있다.

2.3 규칙과 학습의 하이브리드

학습 정책에 규칙적 구조를 결합하려는 시도는 여러 형태로 존재한다. 안전 강화 학습 분야의 실드(shielding)는 안전 조건을 위반하는 행동을 규칙이 차단하는 구조이며(Alshiekh et al., 2018), 옵션 프레임워크(Sutton, Precup, & Singh, 1999)는 시간적으로 확장된 행동 단위를 계층화한다. 본 연구의 제1계층은 실드와 유사하게 학습 정책의 상위에서 개입하지만, 위험 행동의 차단이 아니라 필수 협동 행동의 강제라는 점, 그리고 개입 구간의 표본을 학습에서 제외하고 보상을 준마르코프 방식으로 귀속시킨다는 점에서 구별된다. 게임 도메인에서는 사람의 시연으로 정책을 초기화하는 행동 복제(behavior

cloning)가 AlphaStar의 초기 단계에서 대규모로 활용된 바 있으며(Vinyals et al., 2019), 본 연구도 규칙 기반 정책의 시연을 이용한 행동 복제 초기화를 채택한다.

2.4 인간과 함께 플레이하는 에이전트

학습된 에이전트가 학습 시 경험하지 못한 인간과 협동해야 할 때, 자기 대전 (self-play) 상대에 과적합된 정책은 인간 파트너와의 협동에서 성능이 급락할 수 있음이 보고되어 왔다(Carroll et al., 2019). 본 연구의 환경은 파티 4인 중 1인이 실제 플레이어라는 점에서 이 문제에 직접 노출된다. 이에 대응하여 학습 중 플레이어 슬롯을 채우는 스크립트 모델의 성향과 노이즈를 에피소드마다 랜덤화하는 도메인 랜덤화(Tobin et al., 2017)를 적용하고, 평가를 성향별로 분리하여 보고한다.

3. 시스템 설계

3.1 전체 구조

시스템은 전투 판정을 담당하는 Python 시뮬레이션 서버와 렌더링·조작을 담당하는 Unity 6 클라이언트로 구성된다. 서버는 0.3초 간격의 이산 턴으로 전투를 진행하며, 스냅샷 (보스·유닛 상태, 텔레그래프 도형, 이벤트)을 UDP로 클라이언트에 전송하고 플레이어의 행동 명령을 TCP로 수신한다. 조작감을 위해 플레이어의 이동은 클라이언트가 권위를 갖고(20Hz 위치 스트림, 서버는 속도 상한과 충돌만 검증), 피격·명중·쿨다운·기믹 판정 등 전투 결과는 서버가 권위를 갖는 분리 구조를 사용한다. NPC의 의사결정은 전적으로 서버 측에서 수행되므로, 학습 시에는 Unity 없이 서버만 헤드리스로 구동하여 실시간 제약 없이 에피소드를 진행할 수 있다.

3.2 보스와 전장

보스는 FSM으로 제어되며 모든 실험 조건에서 동일하게 동작한다. 체력 구간 75%/50%에서 페이즈가 전환되고, 50% 도달 시 전멸기가 강제 발동된다. 패턴은 방향성 근접 연타, 지면 광역기, 표식 대상 추격 돌진(기동에 유도하여 충돌시키면 그로기), 카운터 유도기(정면에서 카운터 스킬로 저지), 패링 유도기(확산 원을 패링 스킬로 파훼), 낙인 (대상이 파티에서 이격해야 함), 전멸기(순차적으로 폭발하는 기동 중 최종 생존 기동

Table 1**제1계층 행동 트리의 우선순위 규칙**

순위	규칙	조건 → 행동
1	전멸기 은신	전멸기 시전 중 → 최종 생존 기동 뒤 시야 차단 지점으로 이동
2	임박 위험 회피	위험 도형 안 $\wedge$ 발동 잔여 ≤ 2 턴 → 최단 탈출 (탱커는 가드 가능 시 가드)
3	낙인 산개	낙인 대상 → 파티로부터 이격 이동
4	무력화 집중	보스 그로기 → 근접 확보 후 집중 공격 (탱커는 도발 우선)
5	패링 장판 탈출	패링 유도 원 안 (NPC는 패링 불가) → 원 밖 탈출
6	돌진 유도	추격 돌진 표식이 자신 → 기동 후방으로 이동해 충돌 유도
—	위임	어느 규칙도 미발화 → 제2계층(RL)

뒤에 전원이 시야 차단 은신) 등 11종이다. 상시 무력화 게이지가 존재하여 파티의 누적 타격으로 게이지를 소진시키면 보스가 그로기 상태가 되며, 전장은 보스 체력에 연동되어 단계적으로 축소되는 원형 경기장이다.

3.3 파티와 행동 공간

파티는 실제 플레이어(딜러)와 NPC 3인(탱커, 힐러, 서포터)으로 구성된다. 관측은 자기 상태, 파티원 상대 상태, 보스 상태(패턴, 남은 시전 턴, 무력화 게이지), 위험 도형 요약 등 132차원 벡터이고, 행동은 정지·8방향 이동·평타·역할 스킬·회피 기동·카운터 등 22종의 이산 행동이다. 역할별 스킬 구성은 게임 규칙으로 고정된다 (탱커: 도발·가드, 힐러: 단일/광역 회복, 서포터: 공격·보호 버프).

4. 제안 방법: 2계층 하이브리드 의사결정

4.1 제1계층: 기믹 행동 트리

제1계층은 매 턴 우선순위 순서로 평가되는 결정론적 규칙 집합이다. 규칙이 발화하면 해당 행동이 확정되고, 어떤 규칙도 발화하지 않으면 제어가 제2계층으로 넘어간다 (표 1). 규칙은 발생 빈도가 낮고 실패 비용이 큰 기믹에 한정하며, 일반적인 포지셔닝·공격·회복 판단은 의도적으로 포함하지 않는다. 특히 임박 위험 회피 규칙은 위험 도형 안에 있더라도 발동까지 여유가 있으면(잔여 3턴 이상) 발화하지 않는데, 이는 “위험을 미리 벗어나는 선제적 포지셔닝”을 제2계층의 학습 대상으로 남겨 두기 위함이다.

4.2 제2계층: 역할별 PPO

제2계층은 탱커·힐러·서포터 각각 독립된 액터-크리틱 네트워크(공유 은닉 2층 256유닛)로 구성되며 PPO로 학습된다. 보상은 팀 공통 항(보스 처치, 파티 생존, 시간 패널티)과 역할 항(탱커: 어그로 유지, 힐러: 유효 회복과 위급 대상 우선, 서포터: 버프 적중과 보조 딜)의 합이며, 위험 도형 안에 있는 동안은 양(+)의 역할 보상이 차단되어 회피가 우선되도록 한다. 중요한 설계는 기믹 관련 보상(은신 성공, 산개, 카운터, 돌진 유도 등)을 제2계층 보상에서 전부 제거한 것이다. 기믹은 제1계층이 보장하므로, 제2계층은 순수 전투 보상만으로 학습하여 신호가 명료해지고 탐색 공간이 줄어든다.

4.3 준마르코프 표본 수집

학습 중에도 제1계층은 활성 상태이므로, 롤아웃에는 RL이 결정한 턴과 BT가 결정한 턴이 섞여 있다. BT가 결정한 턴을 RL의 학습 표본으로 사용하면 정책이 생성하지 않은 행동으로 정책 경사가 추정되는 오염이 발생한다. 이를 피하기 위해 BT 발화 턴은 표본에서 제외하되, 해당 턴들에서 발생한 보상은 직전 RL 결정의 보상에 누적 귀속시킨다. 즉 RL 관점에서 하나의 결정은 “다음 RL 결정까지의 구간”을 갖는 시간 확장 행동이 되며, 이는 옵션 프레임워크(Sutton et al., 1999)의 준마르코프 전이와 같은 구조이다.

4.4 학습 절차

학습은 다음 요소를 결합한다. (a) 행동 복제 초기화: 규칙 기반 기준 정책 (FSM)의 시연 2,000 에피소드로 각 역할 네트워크를 교차 엔트로피 손실로 사전 학습한다. (b) 커리큘럼: 보스 체력을 12,000 → 28,000 → 55,000(실전 값)의 3단계로 증가시키며, 최근 승률이 40%에 도달하면 승급한다(Bengio et al., 2009). (c) 플레이어 도메인 랜덤화: 플레이어 슬롯을 채우는 스크립트 모델의 성향을 에피소드마다 공격형(회피 지연)·안정형(회피 우선)·미숙형(확률적 오행동)에서 샘플링하고 이동 지터·스킬 지연 노이즈를 부여한다. (d) 학습-배포 일치: 배포 시 반응 지연 모사를 위해 관측을 1턴 지연시키므로, 학습 롤아웃에서도 동일한 지연 관측을 사용한다. (e) 엔트로피 감시: 사전 실험에서 관찰된 엔트로피 붕괴-성능 퇴행을 조기 탐지하기 위해 역할별 정책 엔트로피를 학습 로그에

기록하고, 붕괴 시 이전 체크포인트로 롤백한다.

배포 시(실제 게임) 제2계층에는 사람다움을 위한 두 장치가 추가된다. 온도 1.0의 확률적 샘플링(결정론적 argmax 금지)과, 직전 이동 방향에 로짓 보너스를 주는 행동 관성(지터 억제)이다. 학습된 모델이 없는 경우 제2계층은 규칙 기반 정책으로 대체되어 게임은 항상 구동 가능하다.

5. 실험

5.1 사전 실험: 순수 강화학습의 실패

본 연구 설계의 직접적 근거가 된 사전 실험을 요약한다. 동일 계열의 보스 전투 환경에서 역할별 PPO 정책을 기믹 보상을 포함한 단일 보상으로 약 30만 에피소드 학습시켰을 때, (a) 협동 기믹(무력화 시간 창 대응 등)의 수행률이 학습 후반까지 안정화되지 않았고, (b) 약 16만 에피소드 이후 정책 엔트로피가 붕괴하며 승률이 오히려 하락하는 퇴행이 관찰되었다. 이후 관측 설계 변경과 보상 재설계를 결합한 반복 실험(하이브리드 보상 조정 8회)을 통해 승률 56%, 무력화 기여 37% 수준까지 개선되었으나, 이는 대규모 반복 튜닝의 결과였으며 기믹의 결정론적 보장은 끝내 확보되지 않았다. 이 경험은 “기믹 수행을 학습으로 획득하는 것”과 “기믹 수행을 규칙으로 보장하고 학습은 전투에 집중시키는 것”의 비용 차이를 보여 주며, 본 연구의 2계층 분리 설계로 이어졌다.

5.2 실험 설정

제안 구조의 학습은 행동 복제 2,000 에피소드에 이어 총 20,000 에피소드의 PPO로 진행되었으며, 단일 데스크톱(GPU 1기) 기준 약 12.6시간(분당 약 26 에피소드)이 소요되었다. 학습 중 평가는 200 에피소드 주기로 24 에피소드씩 수행하고, 최종 평가는 학습 종료 후 120 에피소드로 수행하였으며, 플레이어 성향별 승률을 분리 집계하였다. 비교 기준은 세 가지이다: (A) 규칙 기반 NPC(FSM), (B) 순수 RL(사전 실험 결과로 같음), (C) 제안 하이브리드. 기준 정책 (A)는 동일 환경에서 승률 64–75%를 기록한다.

Table 2최종 평가 결과 (학습 종료 후, 최종 난이도, $n = 120$)

지표	값
승률	70.8% (규칙 기반 기준 정책 64–75%)
평균 처치 시간	754턴 $\approx$ 3.8분 (제한 1,300턴)
기믹 성공률	86.9%
제1계층(BT) 발화 비율	전체 NPC 턴의 21.8%
성향별 승률	공격형 82.2%, 안정형 71.8%, 미숙형 55.6%
정책 엔트로피	학습 전 구간 붕괴 미관찰 (역할별 로그 감시)

5.3 결과

커리큘럼 1단계(체력 12,000)는 약 80 에피소드, 2단계(28,000)는 수천 에피소드 내에 통과하였고, 최종 단계(55,000, 실전 밸런스)에서 나머지 학습이 진행되었다. 표 2은 학습 종료 후 최종 난이도에서 120 에피소드로 수행한 평가 결과를 요약한다.

세 가지 관찰이 주목된다. 첫째, 기믹 성공률이 학습 초기부터 종료까지 85% 내외로 일정하게 유지되었다. 이는 기믹 수행이 학습의 산물이 아니라 제1계층의 결정론적 보장에서 나온다는 설계 의도와 부합하며, 30만 에피소드로도 기믹이 안정화되지 않은 순수 RL 사전 실험과의 가장 뚜렷한 대비점이다. 둘째, BT 발화 비율이 약 22%로, NPC 행동의 대부분(78%)은 학습 정책이 결정한다. 즉 규칙은 병목 구간만 점유하고 행동의 다양성은 학습이 담당하는 분업이 성립하며, 이 분업 하에 최종 승률(70.8%)은 규칙 기반 기준(64–75%)과 동등한 수준에 도달하였다. 셋째, 미숙형 플레이어와의 승률이 학습 중반 0–33%에서 최종 55.6%까지 개선되었다. 미숙형은 피격이 잦아 힐러의 부담이 큰 조건인데, 학습이 진행되며 힐러·서포터 정책이 이 조건에 적응한 것으로, 플레이어 성향 랜덤화가 의도한 강건성이 형성되었음을 시사한다.

6. 계획된 평가

6.1 통제 비교

학습 완료 후 동일 보스·동일 플레이어 모델 조건에서 규칙 기반 NPC(A)와 제안 하이브리드(C)를 각 수백 에피소드 평가하여 승률, 처치 시간, 파티 생존율, 역할 지표(어그로 유지율, 유효 회복량, 오버힐 비율 등)를 비교한다. 전투 성능에 대한 가설은

우월성이 아니라 비열등성(규칙 기반과 동등 이상)으로 설정한다. 제안 구조의 기대 이점은 원시 승률의 우위가 아니라, 학습되지 않은 조건(플레이어 성향 변화, 보스 변수 변화)에서의 적응력과 실제 플레이어가 인식하는 협동 품질에 있기 때문이다.

6.2 사용성 평가

실제 플레이어를 대상으로 규칙 기반 NPC 조건과 하이브리드 NPC 조건을 반복 측정 설계(조건 순서 교차 배치)로 플레이하게 하고, 역할 수행도, 협동성, 신뢰도, 예측 가능성, 상황 적응성을 리커트 척도로 측정한다. 설문 문항은 인간-로봇 신뢰의 다차원 척도(Malle & Ullman, 2021) 등 기존 검증 척도를 게임 맥락에 변안하여 구성하고 내적 일관성(Cronbach's α)을 확인한다. 아울러 전투 로그 기반의 객관 지표와 주관 평가 간 상관관계를 분석하여, 객관적 역할 수행과 인식된 협동 경험의 관계 — 특히 학습 정책의 행동 다양성이 예측 가능성 인식과 상충하는지 — 를 검토한다. 이 분석은 결과가 어느 방향으로 나타나든 하이브리드 구조의 계층 배분 (무엇을 규칙으로, 무엇을 학습으로)에 대한 설계 시사점을 제공한다.

7. 한계 및 향후 과제

본 초안 시점의 한계는 다음과 같다. 첫째, 순수 RL 대조군(B)은 동일 환경의 재 학습이 아니라 동일 계열 환경의 사전 실험으로 갈음하고 있어, 엄밀한 동일 조건 비교를 위해서는 현행 환경에서의 재학습이 필요하다. 둘째, 규칙 기반 기준(A)과의 비교는 단일 평가 배치 기준이며, 반복 학습(다중 시드)에 따른 분산과 통계 검정은 향후 과제이다. 셋째, 학습 중 플레이어는 스크립트 모델이므로, 성향 랜덤화에도 불구하고 실제 인간 행동 분포와의 간극은 사용성 평가를 통해 확인되어야 한다. 넷째, 제1계층 규칙은 현행 11개 패턴에 수동 설계된 것으로, 새 패턴 추가 시 규칙 갱신 비용이 발생한다. 규칙 계층의 자동 구성 또는 학습 기반 보조는 흥미로운 후속 주제이다.

8. 결론

본 연구는 보스 레이드 협동 NPC의 의사결정을 “실패 비용이 극단적인 이산 기믹”과 “맥락 의존적인 연속 전투 판단”으로 분해하고, 전자를 행동 트리, 후자를 역할별

PPO로 담당시키는 2계층 하이브리드 구조를 제안하였다. 순수 강화학습이 30만 에피소드에도 확보하지 못한 기믹 수행 보장을 규칙 계층이 즉시 제공하는 가운데, 행동의 78%는 학습 정책이 결정하며, 2만 에피소드 학습만으로 최종 난이도 승률 70.8%로 규칙 기반 기준(64-75%)과 동등한 전투 성능에 도달하였다. 미숙한 플레이어 모델과의 협동 승률이 학습에 따라 0%대에서 56%까지 개선된 결과는, 성향 랜덤화가 실제 플레이어와의 협동을 겨냥한 강건성으로 이어졌음을 시사한다. 실제 플레이어 사용성 평가를 통해, 제안 구조가 수치 성능을 넘어 “함께 플레이하고 싶은 파티원”으로 인식되는지를 검증하는 것이 남은 과제이다.

참고문헌

- Alshiekh, M., Bloem, R., Ehlers, R., Könighofer, B., Niekum, S., & Topcu, U. (2018). Safe reinforcement learning via shielding. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), 2669–2678.
- Bengio, Y., Louradour, J., Collobert, R., & Weston, J. (2009). Curriculum learning. *Proceedings of the 26th International Conference on Machine Learning*, 41–48.
- Berner, C., Brockman, G., Chan, B., Cheung, V., Dębiak, P., Dennison, C., ... Zhang, S. (2019). Dota 2 with large scale deep reinforcement learning. *arXiv preprint arXiv:1912.06680*.
- Carroll, M., Shah, R., Ho, M. K., Griffiths, T., Seshia, S., Abbeel, P., & Dragan, A. (2019). On the utility of learning about humans for human-AI coordination. *Advances in Neural Information Processing Systems*, 32.
- Isla, D. (2005). Handling complexity in the Halo 2 AI. *Proceedings of the Game Developers Conference*.
- Jaderberg, M., Czarnecki, W. M., Dunning, I., Marris, L., Lever, G., Castañeda, A. G., ... Graepel, T. (2019). Human-level performance in 3D multiplayer games with population-based reinforcement learning. *Science*, 364(6443), 859–865.
- Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. (2017). Multi-agent actor-critic for mixed cooperative-competitive environments. *Advances in Neural Information Processing Systems*, 30.
- Malle, B. F., & Ullman, D. (2021). A multidimensional conception and measure of human-robot trust. In C. S. Nam & J. B. Lyons (Eds.), *Trust in human-robot interaction* (pp. 3–25). Academic Press.
- Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J., & Whiteson, S. (2018). QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning. *Proceedings of the 35th International Conference on Machine Learning*, 4295–4304.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy

- optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- Sutton, R. S., Precup, D., & Singh, S. (1999). Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial Intelligence*, 112(1–2), 181–211.
- Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., & Abbeel, P. (2017). Domain randomization for transferring deep neural networks from simulation to the real world. *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 23–30.
- Vinyals, O., Babuschkin, I., Czarnecki, W. M., Mathieu, M., Dudzik, A., Chung, J., ... Silver, D. (2019). Grandmaster level in StarCraft II using multi-agent reinforcement learning. *Nature*, 575(7782), 350–354.
- Wang, T., Dong, H., Lesser, V., & Zhang, C. (2020). ROMA: Multi-agent reinforcement learning with emergent roles. *Proceedings of the 37th International Conference on Machine Learning*, 9876–9886.