

보스 레이드 협동 NPC를 위한 실패 비용 기반 규칙-강화학습 제어권 분리와 준마르코프 학습

박준형

메타버스 테크놀로지, 서강대학교 가상융합전문대학원

초록

보스 레이드의 파티원 NPC는 일반 전투 판단뿐 아니라 실패 시 파티 전멸로 이어지는 필수 기믹을 수행해야 한다. 일반 전투 판단은 전투 상태와 플레이어 행동에 따라 적절한 행동이 달라지는 반면, 필수 기믹은 발생 빈도가 낮고 실패 비용이 크며 다수 에이전트의 동시 성공을 요구한다. 이처럼 성격이 다른 행동을 단일 규칙 체계나 단일 강화학습 정책으로 처리하면 각각 유지보수 비용 증가와 희소 보상에 따른 학습 불안정 문제가 발생하며, 실제로 저자의 사전 실험에서 순수 강화학습 정책은 약 30만 에피소드의 학습에도 기믹 수행을 안정화하지 못했다. 본 연구는 보스 레이드 행동을 실패 비용과 판단의 결정성이라는 두 기준으로 분류하여 제어 방식을 분리하는 2계층 협동 NPC 구조를 제안한다. 제1계층의 행동 트리(behavior tree)는 전멸기 회피, 낙인 산개 등 저빈도·고실패비용 기믹을 결정론적으로 보장하고, 제2계층의 역할별(탱커·힐러·서포터) 독립 PPO 정책은 포지셔닝, 어그로 관리, 회복 대상 선택과 같은 맥락 의존적 일반 전투 판단을 담당한다. 나아가 행동 트리가 PPO의 제어권을 대체한 턴을 on-policy 학습 표본에서 제외하고, 해당 구간의 할인 보상을 직전 PPO 결정에 누적하여 다음 PPO 결정까지를 가변 길이 준마르코프(semi-Markov) 전이로 구성하는 표본 수집 방식을 제시한다. 제안 구조는

실제 플레이어 1인과 NPC 3인이 협동하는 자체 제작 보스 레이드 게임(Unity 클라이언트 + Python 시뮬레이션 서버)에 구현되었으며, 행동 복제 초기화, 보스 체력 3단계 커리큘럼, 플레이어 성향(공격형·안정형·미숙형) 도메인 랜덤화를 결합해 20,000 에피소드를 학습한 결과, 기믹 성공률 86.9%를 유지하면서 최종 난이도 승률 70.8%(120 에피소드 평가)로 규칙 기반 기준 정책(64-75%)과 동등한 수준에 도달하였다. 이때 행동 트리가 개입한 턴은 전체 NPC 턴의 21.8%에 그쳐, 제한된 결정론적 개입만으로 기믹 신뢰성과 학습 기반 행동 다양성이 양립할 수 있음을 시사한다. 규칙 기반·순수 PPO·표본 혼합 방식과의 통제 비교, 표본 처리 제거 실험, 실제 플레이어 대상 사용성 평가는 계획된 향후 과제로 제시한다.

주요어: 협동 NPC, 보스 레이드, 행동 트리, 강화학습, 제어권 분리, 준마르코프 의사결정 과정, PPO

1. 서론

MMORPG의 보스 레이드는 탱커, 딜러, 힐러와 같이 역할이 구분된 파티원이 보스의 공격 패턴에 실시간으로 대응하며 협동해야 하는 콘텐츠이다. 파티원의 일부 또는 전부를 NPC로 대체하려는 수요는 꾸준히 존재하지만 — 예컨대 파티 매칭이 어려운 시간대의 솔로 플레이 지원이나 싱글 플레이어 게임에서의 동료 시스템 — 상용 게임의 동료 NPC는 대부분 유한 상태 기계(finite state machine, FSM)나 행동 트리(behavior tree, BT)와 같은 규칙 기반 기법으로 구현된다(Isla, 2005). 규칙 기반 NPC는 동작이 예측 가능하고 필수 행동을 강제할 수 있다는 장점이 있으나, 설계자가 명시하지 않은 상황 — 파티원 조합의 변화, 플레이어의 실수, 패턴의 중첩 — 에서 경직된 행동을 보이며, 행동 규칙이 복잡해질수록 유지 보수 비용이 급격히 증가한다.

강화학습(reinforcement learning, RL)은 이러한 경직성을 극복할 대안으로 주목받아 왔다. 대규모 학습을 통해 StarCraft II(Vinyals et al., 2019)와 Dota 2(Berner et al., 2019)에서 인간 최상위권 수준의 협동 플레이가 달성되었고, 팀 기반 일인칭 게임에서 인간과 함께 플레이할 수 있는 수준의 에이전트도 보고되었다(Jaderberg et al., 2019). 그러나 보스 레이드 환경에 순수 강화학습을 적용할 때는 이들 연구와 구별되는 구조적 난점이 있다. 보스 레이드의 협동 기믹 — 예컨대 특정 시점에 전원이 엄폐물 뒤로 숨어야 하는 전멸기 — 는 (a) 발생 빈도가 낮아 학습 신호가 희소하고, (b) 파티원 전원의 동시 성공을 요구하며, (c) 단 한 번의 실패가 즉시 에피소드 종료 (전멸)로 이어진다. 탐험 과정의 확률적 정책이 이러한 조건을 유연히 만족하기는 어렵고, 실패가 반복되면 기믹 구간 이전의 전투 행동까지 부정확한 귀인으로 오염된다.

이 난점은 이론적 우려에 그치지 않는다. 저자는 본 연구에 앞서 동일 계열의 보스 전투 환경에서 순수 PPO(Schulman et al., 2017) 기반 역할별 정책을 약 30만 에피소드 학습시키는 사전 실험을 수행하였는데, 전투 승률은 일정 수준에서 정체되었고 특히 협동 기믹의 수행은 학습 후반까지 안정화되지 않았다. 나아가 약 16만 에피소드 이후 정책 엔트로피가 붕괴하면서 성능이 오히려 퇴행하는 현상도 관찰되었다. 보상 설계를 바꾸어 가며 반복한 실험들에서 공통적으로 확인된 것은, 기믹 수행과 전투 판단이라는 성격이 다른 두 과제를 단일 정책의 단일 보상 신호로 동시에 학습시키는 접근 자체의 비효율이

었다.

본 연구는 이 관찰로부터, 문제의 근원을 특정 구현 기법의 한계가 아니라 성격이 다른 행동들을 단일 의사결정 방식으로 처리한 데에서 찾는다. 보스 레이드의 NPC 행동은 두 기준으로 분류할 수 있다. 하나는 **실패 비용**, 즉 행동의 실패가 전투 결과에 미치는 영향이고, 다른 하나는 **판단의 결정성**, 즉 주어진 상황에서 올바른 행동이 명확하게 정의될 수 있는 정도이다. 전멸기 발생 시 기둥 뒤로 이동하는 행동은 실패 비용이 극단적이고 정답이 명확한 반면, 현재 공격을 지속할지 후퇴할지의 판단은 실패 비용이 상대적으로 낮고 맥락에 따라 최적 행동이 달라진다. 이에 따라 본 연구는 다음의 설계 원칙을 채택한다: **실패 비용이 높고 정답이 명확한 행동은 규칙으로 보장하고, 실패 비용이 상대적으로 낮으며 맥락에 따라 최적 행동이 달라지는 판단은 강화학습으로 적응시킨다.** 이 원칙 하에 제1계층의 결정론적 BT는 전멸기 은신, 임박한 광역기 회피, 낙인 산개와 같은 저빈도·고실패비용 기믹만을 우선순위 규칙으로 확정 처리하고, 규칙에 해당하지 않는 턴은 역할별로 독립된 제2계층 PPO 정책이 담당한다. 기믹이 제1계층에서 보장되므로 제2계층의 보상에서 기믹 항을 제거할 수 있고, 행동 트리는 전체 NPC 행동을 통제하지 않으며, 강화학습은 모든 행동을 처음부터 탐색할 필요 없이 일반 전투 판단에 집중한다.

행동 트리와 강화학습의 결합 자체는 새로운 시도가 아니다. BT가 여러 학습된 스킬 중 하나를 선택하거나, 트리 내부의 특정 노드를 학습으로 대체하거나, 상위 전략은 규칙이 하위 조작은 학습이 담당하는 선행 연구들이 존재한다. 본 연구의 방법론적 초점은 결합 여부가 아니라, 규칙 기반 제어가 on-policy 학습 알고리즘인 PPO의 제어권을 일시적으로 대체할 때 발생하는 학습 표본 불일치의 처리에 있다. BT가 선택한 행동을 PPO 표본에 그대로 포함하면 정책이 생성하지 않은 행동으로 정책 경사가 추정되는 오염이 발생할 수 있다. 본 연구는 BT 개입 턴을 표본에서 제외하되 해당 구간의 할인 보상을 직전 PPO 결정에 누적하여, 하나의 PPO 결정이 다음 PPO 결정까지의 가변 길이 준마르코프(semi-Markov) 전이를 구성하도록 표본을 수집한다. 준마르코프 결정 과정은 기존 이론이며(Sutton, Precup, & Singh, 1999), 본 연구는 이를 규칙 개입 환경의 on-policy 표본 수집에 적용한다.

제안 구조는 Unity 기반 실시간 클라이언트와 Python 시뮬레이션 서버로 구성된

자체 제작 보스 레이드 게임에 구현되었다. 환경은 11종의 보스 패턴(방향성 근접기, 광역기, 추격 돌진, 카운터 유도기, 패링 유도기, 전멸기 등), 상시 무력화 게이지, 보스 체력에 연동되어 축소되는 원형 전장을 포함하며, 실제 플레이어 1인(딜러)과 NPC 3인(탱커, 힐러, 서포터)이 한 파티를 이룬다. 본 초안은 진행 중인 연구의 시스템 설계, 학습 방법, 그리고 학습 중간 시점의 결과를 보고한다.

본 연구의 기여는 다음과 같이 요약된다. 첫째, 보스 레이드 NPC 행동을 실패 비용과 판단의 결정성에 따라 규칙 기반 제어와 강화학습 제어로 분리하는 설계 원칙을 제안한다. 둘째, 인간 플레이어와 역할별 NPC가 협동하는 보스 레이드 환경에 행동 트리와 역할별 PPO를 결합한 2계층 구조를 실제 플레이 가능한 게임으로 구현하였다. 셋째, 외부 규칙 정책이 PPO의 제어권을 대체하는 구간을 학습 표본에서 제외하고 해당 구간의 할인 보상을 직전 정책 결정에 누적하는 준마르코프 표본 수집 방식을 제시하여, 규칙 개입이 정책 경사 추정을 오염시키는 문제를 다루었다. 넷째, 행동 트리 개입 비율, 기믹 성공률, 전투 성능을 함께 측정하여 제한된 규칙 개입으로 결정론적 보장과 학습 기반 행동 다양성이 양립할 수 있는지를 검증한다. 다섯째, 실제 플레이어와의 협동을 전제로, 학습 중 플레이어 모델의 성향(공격형·안정형·미숙형)을 에피소드마다 랜덤화하는 도메인 랜덤화(Tobin et al., 2017)를 적용하고 성향별 성능을 보고한다. 아울러 순수 강화학습 사전 실험의 실패 관찰을 포함한 설계 근거와 학습 중간 지표를 공개하여, 동일 문제를 다루는 후속 연구의 기준점을 제공한다.

2. 관련 연구

2.1 게임 NPC의 규칙 기반 제어

FSM과 BT는 상용 게임 AI의 표준적 기법이다. 특히 BT는 우선순위가 있는 조건-행동 규칙을 트리로 구조화하여 복잡한 행동의 조합과 재사용을 용이하게 하며, Halo 2 이후 다수의 상용 게임에서 채택되었다(Isla, 2005). 규칙 기반 제어의 강점은 결정론적 보장이다. 즉 특정 조건에서 특정 행동이 반드시 수행됨을 설계 시점에 확정할 수 있다. 본 연구는 이 강점을 폐기하지 않고, 실패 비용이 극단적인 기믹 구간에 한정하여 활용한다.

2.2 다중 에이전트 강화학습과 역할

다중 에이전트 강화학습(MARL)에서는 중앙 집중 학습-분산 실행 패러다임 하에 가치 분해(Rashid et al., 2018)나 중앙 비평가(Lowe et al., 2017)를 통해 협동 행동을 학습하는 접근이 주류를 이룬다. 역할의 관점에서는, 에이전트를 역할 공간에 분화시켜 탐색을 구조화하는 ROMA(Wang et al., 2020)와 같이 역할을 학습의 산물로 창발시키는 연구가 있다. 반면 본 연구의 대상인 보스 레이드는 탱커·힐러·서포터라는 역할이 게임 규칙(스킬 구성, 능력치)으로 사전에 고정되어 있으므로, 역할을 창발시키는 대신 역할별로 독립된 관측·정책·보상을 부여하는 명시적 역할 분리를 채택한다. 이는 각 역할의 행동 공간에서 불가능한 행동(예: 탱커의 회복)을 제거하고 보상 신호를 역할 목적에 정렬시키는 실용적 이점이 있다.

2.3 규칙과 학습의 하이브리드

학습 정책에 규칙적 구조를 결합하려는 시도는 여러 형태로 존재한다. 게임 도메인의 BT-RL 결합 연구는 주로 BT가 여러 학습된 스킬 중 하나를 선택하거나, 트리 내부의 특정 노드를 학습으로 대체하거나, 상위 전략은 규칙이 하위 조작은 학습이 담당하거나, 규칙이 학습 정책의 위험 행동을 차단하는 구조를 사용한다. 안전 강화학습 분야의 실드(shielding)는 안전 조건을 위반하는 행동을 규칙이 차단하는 구조이며(Alshiekh et al., 2018), 옵션 프레임워크(Sutton, Precup, & Singh, 1999)는 시간적으로 확장된 행동 단위를 계층화한다. 본 연구의 제1 계층은 실드와 유사하게 학습 정책의 상위에서 개입하지만, 위험 행동의 차단이 아니라 필수 협동 행동의 강제라는 점, 그리고 개입 구간의 표본을 학습에서 제외하고 보상을 준마르코프 방식으로 귀속시킨다는 점에서 구별된다. 게임 도메인에서는 사람의 시연으로 정책을 초기화하는 행동 복제(behavior cloning)가 AlphaStar의 초기 단계에서 대규모로 활용된 바 있으며(Vinyals et al., 2019), 본 연구도 규칙 기반 정책의 시연을 이용한 행동 복제 초기화를 채택한다.

국내에서도 규칙 기반 제어와 강화학습을 결합하려는 시도가 이어지고 있다. 김동주와 고석주(2025a)는 모바일 자동 진행 RPG에서 FSM과 심층 Q-학습을 결합하여 개별 NPC의 전투 성능을 개선하였고, 후속 연구(김동주 & 고석주, 2025b)는 클라이언트가 FSM

과 BT로 즉각적 전술 행동을, 서버가 PPO와 다중 에이전트 강화학습으로 고차원 전략을 담당하는 분산형 하이브리드 구조를 제안하였다. 다만 이들 연구의 계층 분리 기준은 연산 부하와 응답성이며, 규칙이 학습 정책의 제어권을 대체한 구간의 학습 표본 처리는 다루지 않는다. 본 연구는 분리 기준을 실패 비용과 판단의 결정성으로 설정하고, 규칙 개입 구간의 on-policy 표본 불일치를 명시적으로 처리한다는 점에서 구별된다.

2.4 인간과 함께 플레이하는 에이전트

학습된 에이전트가 학습 시 경험하지 못한 인간과 협동해야 할 때, 자기 대전 (self-play) 상대에 과적합된 정책은 인간 파트너와의 협동에서 성능이 급락할 수 있음이 보고되어 왔다(Carroll et al., 2019). 본 연구의 환경은 파티 4인 중 1인이 실제 플레이어라는 점에서 이 문제에 직접 노출된다. 이에 대응하여 학습 중 플레이어 슬롯을 채우는 스크립트 모델의 성향과 노이즈를 에피소드마다 랜덤화하는 도메인 랜덤화(Tobin et al., 2017)를 적용하고, 평가를 성향별로 분리하여 보고한다.

보스 레이드를 대상으로 한 국내 연구로, 전준렬과 홍진혁(2025)은 4인 파티 전체를 다중 에이전트 강화학습(MA-POCA)으로 동시 조종하면서 인간 플레이 데이터를 활용해 인간다운 플레이 패턴을 모방하는 접근을 제안하였다. 해당 연구는 파티 전원이 학습 에이전트이고 인간다움의 재현이 목표인 반면, 본 연구는 파티에 실제 플레이어가 포함된 상태에서 NPC가 그와 협동하는 문제를 다루며 기믹 수행의 결정론적 보장을 목표로 한다는 점에서 문제 설정이 다르다.

2.5 기존 행동 트리-강화학습 결합 연구와의 차이

단순히 행동 트리와 PPO를 결합했다는 사실만으로는 선행 연구와의 차별성을 확보하기 어렵다. 본 연구가 기존 BT-RL 결합 연구와 구별되는 지점을 표 1에 정리한다. 핵심 차이는 세 가지이다. (a) 행동의 복잡도나 계층 구조가 아니라 실패 비용과 판단의 결정성을 제어권 분리 기준으로 삼는다. (b) 규칙 개입 구간을 개별 노드의 학습 문제가 아니라 on-policy 표본 수집의 문제로 다루어, 개입 턴을 표본에서 제외하고 보상을 직전 학습 결정에 누적한다. (c) 실제 인간 플레이어와 역할이 고정된 NPC가 협동하는 레이드 환경에서, 성능 향상 자체가 아니라 기믹 보장과 적응적 협동의 양립을 평가 목표로 삼

Table 1

기존 행동 트리-강화학습 결합 연구와 본 연구의 차이

구분	기존 BT-RL 결합	본 연구
분리 기준	행동 복잡도나 스킬 종류	실패 비용과 판단의 결정성
BT의 역할	RL 스킬 선택 또는 상위 전략	필수 기믹 행동의 직접 보장
RL의 역할	개별 스킬 또는 하위 제어	역할별 일반 전투 판단
연구 환경	단일 에이전트 또는 경쟁 전투	인간 1인·NPC 3인의 협동 레이드
역할 구조	일반적 NPC 행동	탱커·힐러·서포터 역할 고정
필수 기믹	제한적으로 다름	전멸 및 동시 성공 기믹 중심
규칙 개입 처리	개별 노드 학습 중심	개입 턴 표본 제외와 보상 누적
평가 목표	성능 향상, 학습 효율	기믹 보장과 적응적 협동의 양립
인간 플레이어	없는 경우가 많음	실제 인간 플레이어와 협동
플레이어 다양성	제한적	성향 도메인 랜덤화 적용

는다.

3. 연구 질문과 가설

본 연구가 답하고자 하는 연구 질문(RQ)과 그에 대응하는 가설(H)은 다음과 같다. 본 초안의 학습 결과(6절)는 RQ1, RQ2, RQ4, RQ5에 대한 예비 증거를 제공하며, RQ3과 RQ6은 계획된 평가(7절)를 통해 검증할 예정이다.

- **RQ1 (기믹 보장).** 행동 트리 기반 필수 기믹 계층은 순수 강화학습 정책보다 보스 레이드의 저빈도·고실패비용 기믹을 안정적으로 수행하는가?
- **RQ2 (전투 성능).** 필수 기믹을 행동 트리에 분리한 역할별 PPO는 규칙 기반 NPC와 비교하여 비열등한 전투 성능을 달성하는가?
- **RQ3 (학습 안정성).** 행동 트리 개입 턴을 PPO 표본에서 제외하고 보상을 직전 결정에 누적하는 방식은 단순 표본 혼합 방식보다 학습 안정성을 개선하는가?
- **RQ4 (제어권 분업).** 제한된 행동 트리 개입만으로 기믹 성공률을 유지하면서 대부분의 일반 전투 행동을 강화학습 정책에 맡길 수 있는가?
- **RQ5 (플레이어 강건성).** 플레이어 성향 도메인 랜덤화를 적용한 협동 NPC는 학습에 사용되지 않은 플레이어 행동 특성에서도 성능을 유지하는가?

- **RQ6 (사용자 경험).** 하이브리드 NPC는 순수 규칙 기반 NPC와 비교하여 역할 수행도, 협동성, 상황 적응성 및 신뢰도에서 차이를 보이는가?

각 연구 질문에 대응하는 가설은 다음과 같다.

- **H1.** 행동 트리가 필수 기믹을 담당하는 조건은 순수 PPO 조건보다 높은 기믹 성공률을 보일 것이다.
- **H2.** 하이브리드 NPC의 보스 레이드 승률은 규칙 기반 NPC와 비교해 비열등할 것이다.
- **H3.** 준마르크프 보상 귀속 방식을 사용한 PPO는 BT 행동을 표본에 포함하는 단순 혼합 방식보다 안정적인 정책 엔트로피와 낮은 가치 손실을 보일 것이다.
- **H4.** 하이브리드 NPC는 전체 행동 중 제한된 비율에서만 행동 트리가 개입하더라도 높은 기믹 성공률을 유지할 것이다.
- **H5.** 플레이어 성향 랜덤화를 적용한 정책은 단일 플레이어 모델로 학습한 정책보다 미학습 플레이어 성향에서 높은 승률을 보일 것이다.
- **H6.** 하이브리드 NPC는 규칙 기반 NPC보다 상황 적응성과 행동 다양성 평가가 높으면서도 예측 가능성과 신뢰도는 유사한 수준을 유지할 것이다.

4. 시스템 설계

4.1 전체 구조

시스템은 전투 판정을 담당하는 Python 시뮬레이션 서버와 렌더링·조작을 담당하는 Unity 6 클라이언트로 구성된다. 서버는 0.3초 간격의 이산 턴으로 전투를 진행하며, 스냅샷(보스·유닛 상태, 텔레그래프 도형, 이벤트)을 UDP로 클라이언트에 전송하고 플레이어의 행동 명령을 TCP로 수신한다. 조작감을 위해 플레이어의 이동은 클라이언트가 권위를 갖고(20Hz 위치 스트림, 서버는 속도 상한과 충돌만 검증), 피격·명중·쿨다운·기믹 판정 등 전투 결과는 서버가 권위를 갖는 분리 구조를 사용한다. NPC의 의사결정은 전적으로

서버 측에서 수행되므로, 학습 시에는 Unity 없이 서버만 헤드리스로 구동하여 실시간 제약 없이 에피소드를 진행할 수 있다.

4.2 보스와 전장

보스는 FSM으로 제어되며 모든 실험 조건에서 동일하게 동작한다. 체력 구간 75%/50%에서 페이즈가 전환되고, 50% 도달 시 전멸기가 강제 발동된다. 패턴은 방향성 근접 연타, 지면 광역기, 표식 대상 추격 돌진(기동에 유도하여 충돌시키면 그로기), 카운터 유도기(정면에서 카운터 스킬로 저지), 패링 유도기(확산 원을 패링 스킬로 파훼), 낙인(대상이 파티에서 이격해야 함), 전멸기(순차적으로 폭발하는 기동 중 최종 생존 기동 뒤에 전원이 시야 차단 은신) 등 11종이다. 상시 무력화 게이지가 존재하여 파티의 누적 타격으로 게이지를 소진시키면 보스가 그로기 상태가 되며, 전장은 보스 체력에 연동되어 단계적으로 축소되는 원형 경기장이다.

4.3 파티와 행동 공간

파티는 실제 플레이어(딜러)와 NPC 3인(탱커, 힐러, 서포터)으로 구성된다. 관측은 자기 상태, 파티원 상대 상태, 보스 상태(패턴, 남은 시전 턴, 무력화 게이지), 위험 도형 요약 등 132차원 벡터이고, 행동은 정지·8방향 이동·평타·역할 스킬·회피 기동·카운터 등 22종의 이산 행동이다. 역할별 스킬 구성은 게임 규칙으로 고정된다(탱커: 도발·가드, 힐러: 단일/광역 회복, 서포터: 공격·보호 버프).

5. 제안 방법: 실패 비용 기반 제어권 분리와 준마르코프 학습

5.1 행동 분류 기준: 실패 비용과 판단의 결정성

제안 구조의 출발점은 구현 난이도가 아니라 행동의 성격에 따른 분류이다. 실패 비용은 행동의 실패가 전투 결과에 미치는 영향이다. 공격 위치 선정, 스킬 선택, 회복 시점 판단은 실패해도 손실이 국소적이지만, 전멸기 회피, 제한 시간 내 장판 이탈, 낙인 동시 산개는 한 번의 실패가 파티 전멸로 이어질 수 있다. 판단의 결정성은 주어진 상황에서 올바른 행동이 명확하게 정의될 수 있는 정도이다. 전멸기 발생 시 최종 생존 기동 뒤로 이동하는 행동은 정답이 유일하게 정의되는 반면, 현재 공격을 지속할지 후퇴할지는

Table 2

행동 특성에 따른 제어 방식 배분

행동 특성	적용 방식
실패 비용이 높고 정답이 명확함	행동 트리
실패 비용이 낮고 상황 의존적임	강화학습
저빈도이며 탐색이 어려움	행동 트리
고빈도이며 반복 경험 가능함	강화학습
모든 NPC의 동시 성공이 필요함	행동 트리
플레이어 성향에 따라 행동이 달라짐	강화학습

체력, 쿨다운, 파티원의 위치, 보스 상태에 따라 답이 달라진다. 두 기준에 따른 제어 방식의 배분을 표 2에 정리한다. 필수 기믹은 발생 빈도가 낮아 강화학습의 탐색 대상으로 삼기 어렵고 다수 NPC의 동시 성공을 요구하므로 규칙으로 보장하는 것이 적합한 반면, 일반 전투 판단은 고빈도로 반복 경험이 가능하고 플레이어 성향에 따라 행동이 달라져야 하므로 학습이 적합하다. 이 원칙을 통해 강화학습은 모든 행동을 처음부터 탐색할 필요가 없으며, 행동 트리는 전체 NPC 행동을 통제하지 않고 반드시 성공해야 하는 일부 구간만 담당한다.

5.2 제1계층: 기믹 행동 트리

제1계층은 매 턴 우선순위 순서로 평가되는 결정론적 규칙 집합이다. 규칙이 발화하면 해당 행동이 확정되고, 어떤 규칙도 발화하지 않으면 제어가 제2계층으로 넘어간다(표 3). 규칙은 발생 빈도가 낮고 실패 비용이 큰 기믹에 한정하며, 일반적인 포지셔닝·공격·회복 판단은 의도적으로 포함하지 않는다. 특히 임박 위험 회피 규칙은 위험 도형 안에 있더라도 발동까지 여유가 있으면(잔여 3턴 이상) 발화하지 않는데, 이는 “위험을 미리 벗어나는 선제적 포지셔닝”을 제2계층의 학습 대상으로 남겨 두기 위함이다.

5.3 제2계층: 역할별 PPO

제2계층은 탱커·힐러·서포터 각각 독립된 액터-크리틱 네트워크(공유 은닉 2층 256유닛)로 구성되며 PPO로 학습된다. 보상은 팀 공통 항(보스 처치, 파티 생존, 시간 패널티)과 역할 항(탱커: 어그로 유지, 힐러: 유효 회복과 위급 대상 우선, 서포터: 버프 적중과 보조 딜)의 합이며, 위험 도형 안에 있는 동안은 양(+)의 역할 보상이 차단되어

Table 3

제1계층 행동 트리의 우선순위 규칙

순위	규칙	조건 → 행동
1	전멸기 은신	전멸기 시전 중 → 최종 생존 기동 뒤 시야 차단 지점으로 이동
2	임박 위험 회피	위험 도형 안 $\wedge$ 발동 잔여 ≤ 2 턴 → 최단 탈출 (탱커는 가드 가능 시 가드)
3	낙인 산개	낙인 대상 → 파티로부터 이격 이동
4	무력화 집중	보스 그로기 → 근접 확보 후 집중 공격 (탱커는 도발 우선)
5	패링 장판 탈출	패링 유도 원 안 (NPC는 패링 불가) → 원 밖 탈출
6	돌진 유도	추격 돌진 표식이 자신 → 기동 후방으로 이동해 충돌 유도
—	위임	어느 규칙도 미발화 → 제2계층(RL)

회피가 우선되도록 한다. 중요한 설계는 기믹 관련 보상(은신 성공, 산개, 카운터, 돌진 유도 등)을 제2계층 보상에서 전부 제거한 것이다. 기믹은 제1계층이 보장하므로, 제2계층은 순수 전투 보상만으로 학습하여 신호가 명료해지고 탐색 공간이 줄어든다.

5.4 규칙 개입 구간의 준마르코프 표본 처리

학습 중에도 제1계층은 활성 상태이므로, 롤아웃에는 RL이 결정한 턴과 BT가 결정한 턴이 섞여 있다. PPO는 현재 정책이 생성한 행동 표본을 전제로 하는 on-policy 알고리즘이므로, BT가 선택한 행동 a_t 를 상태 s_t 및 정책에서 계산한 로그 확률 $\log \pi(a_t | s_t)$ 와 함께 표본에 그대로 저장하면, 실제 행동 생성 주체는 BT임에도 정책이 생성한 행동처럼 취급되어 정책 경사 추정이 오염될 수 있다.

이를 피하기 위해 BT가 개입한 턴은 정책 학습 표본에서 제외한다. 그러나 해당 구간에서 발생한 보상까지 제거하지는 않는다. 시각 t 의 RL 결정 이후 BT 개입 등으로 다음 RL 결정까지 k 턴이 소요되었다면, 그 구간의 보상을 직전 RL 결정에 누적하여 하나의 가변 길이 전이 $(s_t, a_t, R_t^{(k)}, s_{t+k})$ 를 구성한다. 누적 보상은 할인 합

$$R_t^{(k)} = \sum_{i=0}^{k-1} \gamma^i r_{t+i} \quad (1)$$

으로 정의되며, 여기서 r_{t+i} 는 각 턴에서 발생한 보상, γ 는 할인율, k 는 다음 RL 결정까지의 턴 수이다. BT가 개입하지 않은 턴에서는 $k = 1$ 이 되어 일반적인 1턴 전이와 일치한다.

가치 추정 역시 1턴 전이가 아니라 가변 길이 전이에 대한 시간차 오차

$$\delta_t^{(k)} = R_t^{(k)} + \gamma^k V(s_{t+k}) - V(s_t) \quad (2)$$

를 사용하며, 이점(advantage) 추정도 동일한 가변 길이 전이 위에서 수행된다.

이 구조에서 하나의 RL 결정은 “다음 RL 결정까지의 구간”을 갖는 시간 확장 행동이 되며, 준마르코프 결정 과정과 옵션 프레임워크(Sutton et al., 1999)의 시간 확장 행동과 같은 형태로 해석할 수 있다. 준마르코프 결정 과정 자체는 기존 이론이며, 본 연구의 초점은 이를 규칙 기반 제어가 on-policy 정책의 제어권을 일시적으로 대체하는 환경의 표본 수집에 적용하는 데에 있다. 대안적 처리 방식 — BT 행동을 표본에 그대로 포함하는 단순 혼합과, 개입 턴과 구간 보상을 모두 버리는 제거 방식 — 과의 정량 비교는 제거 실험으로 계획되어 있다(7절).

5.5 학습 절차

학습은 다음 요소를 결합한다. (a) 행동 복제 초기화: 규칙 기반 기준 정책 (FSM)의 시연 2,000 에피소드로 각 역할 네트워크를 교차 엔트로피 손실로 사전 학습한다. (b) 커리큘럼: 보스 체력을 12,000 → 28,000 → 55,000(실전 값)의 3단계로 증가시키며, 최근 승률이 40%에 도달하면 승급한다(Bengio et al., 2009). (c) 플레이어 도메인 랜덤화: 플레이어 슬롯을 채우는 스크립트 모델의 성향을 에피소드마다 공격형(회피 지연)·안정형(회피 우선)·미숙형(확률적 오행동)에서 샘플링하고 이동 지터·스킬 지연 노이즈를 부여한다. (d) 학습-배포 일치: 배포 시 반응 지연 모사를 위해 관측을 1턴 지연시키므로, 학습 롤아웃에서도 동일한 지연 관측을 사용한다. (e) 엔트로피 감시: 사전 실험에서 관찰된 엔트로피 붕괴-성능 퇴행을 조기 탐지하기 위해 역할별 정책 엔트로피를 학습 로그에 기록하고, 붕괴 시 이전 체크포인트로 롤백한다.

배포 시(실제 게임) 제2계층에는 행동의 자연스러움을 위한 두 장치가 추가된다. 온도 1.0의 확률적 샘플링(결정론적 argmax 금지)과, 직전 이동 방향에 로짓 보너스를 주는 행동 관성(지터 억제)이다. 학습된 모델이 없는 경우 제2계층은 규칙 기반 정책으로 대체되어 게임은 항상 구동 가능하다.

6. 실험

6.1 사전 실험: 순수 강화학습의 실패

본 연구 설계의 직접적 근거가 된 사전 실험을 요약한다. 동일 계열의 보스 전투 환경에서 역할별 PPO 정책을 기믹 보상을 포함한 단일 보상으로 약 30만 에피소드 학습시켰을 때, (a) 협동 기믹(무력화 시간 창 대응 등)의 수행률이 학습 후반까지 안정화되지 않았고, (b) 약 16만 에피소드 이후 정책 엔트로피가 붕괴하며 승률이 오히려 하락하는 퇴행이 관찰되었다. 이후 관측 설계 변경과 보상 재설계를 결합한 반복 실험(하이브리드 보상 조정 8회)을 통해 승률 56%, 무력화 기여 37% 수준까지 개선되었으나, 이는 대규모 반복 튜닝의 결과였으며 기믹의 결정론적 보장은 끝내 확보되지 않았다. 이 경험은 “기믹 수행을 학습으로 획득하는 것”과 “기믹 수행을 규칙으로 보장하고 학습은 전투에 집중시키는 것”의 비용 차이를 보여 주며, 본 연구의 2계층 분리 설계로 이어졌다.

6.2 실험 설정

제안 구조의 학습은 행동 복제 2,000 에피소드에 이어 총 20,000 에피소드의 PPO로 진행되었으며, 단일 데스크톱(GPU 1기) 기준 약 12.6시간(분당 약 26 에피소드)이 소요되었다. 학습 중 평가는 200 에피소드 주기로 24 에피소드씩 수행하고, 최종 평가는 학습 종료 후 120 에피소드로 수행하였으며, 플레이어 성향별 승률을 분리 집계하였다. 본 절에서 참조하는 비교 기준은 세 가지이다: (A) 규칙 기반 NPC(FSM), (B) 순수 RL(사전 실험 결과로 같음), (C) 제안 하이브리드. 이 표기는 7절의 비교 조건 A-F와 일치하며, 본 초안의 학습 결과는 조건 F의 표본 수집 방식을 적용한 조건 C에 해당한다. 기준 정책 (A)는 동일 환경에서 승률 64-75%를 기록한다.

6.3 결과

커리큘럼 1단계(체력 12,000)는 약 80 에피소드, 2단계(28,000)는 수천 에피소드 내에 통과하였고, 최종 단계(55,000, 실전 밸런스)에서 나머지 학습이 진행되었다. 표 4은 학습 종료 후 최종 난이도에서 120 에피소드로 수행한 평가 결과를 요약한다.

세 가지 관찰이 주목된다. 첫째, 기믹 성공률이 학습 초기부터 종료까지 85% 내외

Table 4최종 평가 결과 (학습 종료 후, 최종 난이도, $n = 120$)

지표	값
승률	70.8% (규칙 기반 기준 정책 64–75%)
평균 처치 시간	754턴 $\approx$ 3.8분 (제한 1,300턴)
기믹 성공률	86.9%
제1계층(BT) 발화 비율	전체 NPC 턴의 21.8%
성향별 승률	공격형 82.2%, 안정형 71.8%, 미숙형 55.6%
정책 엔트로피	학습 전 구간 붕괴 미관찰 (역할별 로그 감시)

로 일정하게 유지되었다. 이는 기믹 수행이 학습의 산물이 아니라 제1계층의 결정론적 보장에서 나온다는 설계 의도와 부합하며, 30만 에피소드로도 기믹이 안정화되지 않은 순수 RL 사전 실험과의 가장 뚜렷한 대비점이다. 둘째, BT 발화 비율이 약 22%로, NPC 행동의 대부분(78%)은 학습 정책이 결정한다. 즉 규칙은 병목 구간만 점유하고 행동의 다양성은 학습이 담당하는 분업이 성립하며, 이 분업 하에 최종 승률(70.8%)은 규칙 기반 기준(64–75%)과 동등한 수준에 도달하였다. 셋째, 미숙형 플레이어와의 승률이 학습 중반 0–33%에서 최종 55.6%까지 개선되었다. 미숙형은 피격이 잦아 힐러의 부담이 큰 조건인데, 학습이 진행되며 힐러·서포터 정책이 이 조건에 적응한 것으로, 플레이어 성향 랜덤화가 의도한 강건성이 형성되었음을 시사한다.

7. 계획된 평가

6절의 결과는 제안 구조의 학습 결과와 규칙 기반 기준의 참조 수치를 보고한 것으로, 연구 질문 전체에 답하기 위한 통제 비교와 제거 실험은 아직 수행되지 않았다. 본 절은 계획된 평가 설계를 기술하며, 여기에 서술된 실험의 결과는 본 초안에 포함되어 있지 않다.

7.1 비교 조건

동일 보스·동일 플레이어 모델 조건에서 다음 여섯 조건을 비교할 계획이다.

- **조건 A (규칙 기반 NPC).** 모든 기믹과 일반 전투 행동을 FSM 또는 행동 트리로 구현한다.

- **조건 B (순수 PPO).** 기믹과 일반 전투 행동을 모두 역할별 PPO가 결정한다.
- **조건 C (하이브리드 PPO).** 필수 기믹은 행동 트리가, 일반 전투는 역할별 PPO가 담당한다(제안 구조).
- **조건 D (단순 혼합 PPO).** 조건 C와 같은 2계층 구조이되, 행동 트리가 개입한 턴도 PPO 학습 표본에 그대로 포함한다.
- **조건 E (Drop-only PPO).** 행동 트리가 개입한 턴과 해당 구간의 보상을 모두 제거한다.
- **조건 F (SMDP 귀속 PPO).** 행동 트리 개입 턴은 표본에서 제외하되 해당 구간의 보상은 직전 PPO 결정에 누적한다(제안 표본 수집 방식).

현재까지의 상태는 다음과 같다. 조건 A는 기존 구현이 존재하며 동일 환경에서 승률 64~75%를 기록한다. 조건 B는 동일 계열 환경의 사전 실험으로 부분적으로 같음되어 있으나, 엄밀한 비교를 위해서는 현행 환경에서의 재학습이 필요하다. 본 초안의 학습 결과는 조건 F의 표본 수집을 적용한 조건 C에 해당한다. 조건 D와 E는 아직 학습하지 않았다.

7.2 제거 실험

제안한 표본 처리 방식의 기여를 분리 검증하기 위해, 동일한 2계층 구조에서 BT 개입 턴의 처리만 달리하는 제거 실험을 계획한다(표 5). 비교 지표는 최종 승률, 기믹 성공률, 에피소드 보상, 정책 엔트로피, 가치 손실, PPO 클리핑 비율, KL 발산, 수렴까지의 에피소드 수, 학습 중 성능 퇴행 여부, 역할별 행동 분포, 그리고 다중 시드에 걸친 성능 분산이다.

7.3 평가 지표

시스템 평가는 다섯 범주의 지표로 수행할 계획이다. (a) 전투 성능: 보스 처치 성공률, 평균 처치 시간, 파티 생존 인원, 역할별 사망률, 보스에게 입힌 총 피해, 받은 피해량, 제한 시간 초과 비율. (b) 기믹 수행: 전멸기·낙인 산개·위험 장판 회피·돌진

Table 5

계획된 제거 실험: 행동 트리 개입 턴의 표본 처리 방식 비교

조건	BT 행동 표본	BT 구간 보상	목적
단순 혼합 (D)	포함	포함	규칙 개입 표본을 그대로 포함할 때의 학습 불일치 확인
Drop-only (E)	제외	제거	개입 구간 보상 손실이 학습에 미치는 영향 확인
SMDP 귀속 (F)	제외	직전 RL 전이에 누적	제안 표본 수집 방식 검증

유도·무력화 각각의 성공률과 기믹별 실패 원인. (c) 역할 수행: 탱커의 어그로 유지율·보스 정면 노출 시간·파티원 피해 감소량, 힐러의 유효 회복량·과잉 회복량·위급 대상 회복률·파티원 사망 전 회복 실패 비율, 서포터의 버프 유지율·약화 효과 유지율·버프 적용 인원·보조 피해량. (d) 학습 안정성: 정책 엔트로피, 평균 에피소드 보상, 가치·정책 손실, KL 발산, 시드별 성능 분산, 성능 최고점 이후 퇴행 정도. (e) 제어권 분배: 행동 트리 개입 비율, PPO 행동 결정 비율, 기믹별·역할별 BT 개입 횟수, BT 개입 구간의 평균 길이, BT 개입 직전·직후의 행동 변화.

7.4 통제 비교와 가설 검증

조건 간 비교는 각 조건 수백 에피소드의 평가와 다중 시드 학습을 통해 수행하며, 승률, 처치 시간, 파티 생존율, 역할 지표(어그로 유지율, 유효 회복량, 과잉 회복 비율 등)를 비교한다. 전투 성능에 대한 가설(H2)은 우월성이 아니라 *비열등성*(규칙 기반과 동등 이상)으로 설정한다. 제안 구조의 기대 이점은 원시 승률의 우위가 아니라, 학습되지 않은 조건(플레이어 성향 변화, 보스 변수 변화)에서의 적응력과 실제 플레이어가 인식하는 협동 품질에 있기 때문이다. 학습 안정성 가설(H3)은 조건 D·E·F의 제거 실험에서 정책 엔트로피와 가치 손실의 추이로 검증한다.

7.5 사용성 평가

사용성 평가는 본 연구의 중심 기여가 아니라 객관적 시스템 평가를 보완하는 위치에 배치한다. 비교 조건은 규칙 기반 NPC(A)와 하이브리드 NPC(C)이며, 순수 PPO(B)는 기믹 실패로 인해 정상적인 플레이 경험을 제공하기 어려울 경우 사용자 평가 조건에서 제외할 수 있다. 실제 플레이어를 대상으로 두 조건을 반복측정 설계(조건 순서

교차 배치)로 플레이하게 하고, 역할 수행의 적절성, 플레이어 행동에 대한 대응, 협동 대상으로서의 신뢰, 행동의 예측 가능성, 상황에 따른 유연성, 그리고 같은 NPC와 다시 플레이하고 싶은지를 리커트 척도로 측정한다. 설문 문항은 인간-로봇 신뢰의 다차원 척도(Malle & Ullman, 2021) 등 기존 검증 척도를 게임 맥락에 번안하여 구성하고 내적 일관성(Cronbach's α)을 확인한다. 아울러 전투 로그 기반의 객관 지표와 주관 평가 간 상관 — 행동 다양성과 상황 적응성 인식, 역할 성공률과 역할 수행 인식, 기믹 성공률과 신뢰도, 행동 변경 빈도와 예측 가능성 인식, 플레이어 성향별 승률과 협동성 평가 — 을 분석하여, 객관적 역할 수행과 인식된 협동 경험의 관계, 특히 학습 정책의 행동 다양성이 예측 가능성 인식과 상충하는지를 검토한다. 이 분석은 결과가 어느 방향으로 나타나는 하이브리드 구조의 계층 배분(무엇을 규칙으로, 무엇을 학습으로)에 대한 설계 시사점을 제공한다.

8. 한계 및 향후 과제

본 초안 시점의 한계는 다음과 같다. 첫째, 순수 RL 대조군(B)은 동일 환경의 재학습이 아니라 동일 계열 환경의 사전 실험으로 같음하고 있어, 엄밀한 동일 조건 비교를 위해서는 현행 환경에서의 재학습이 필요하다. 둘째, 규칙 기반 기준(A)과의 비교는 단일 평가 배치 기준이며, 반복 학습(다중 시드)에 따른 분산과 통계 검정은 향후 과제이다. 셋째, 학습 중 플레이어는 스크립트 모델이므로, 성향 랜덤화에도 불구하고 실제 인간 행동 분포와의 간극은 사용성 평가를 통해 확인되어야 한다. 넷째, 제1계층 규칙은 현행 11개 패턴에 수동 설계된 것으로, 새 패턴 추가 시 규칙 갱신 비용이 발생한다. 규칙 계층의 자동 구성 또는 학습 기반 보조는 흥미로운 후속 주제이다. 다섯째, 준마르코프 표본 처리의 기여는 아직 단순 혼합(D)·Drop-only(E) 조건과의 제거 실험으로 분리 검증되지 않았으며, 이는 계획된 평가(7절)의 핵심 항목이다. 따라서 본 초안은 제안 표본 처리 방식이 대안보다 우수하다고 주장하지 않으며, 해당 주장은 제거 실험 결과에 근거해서만 가능하다.

9. 결론

본 연구는 행동 트리와 강화학습의 단순 결합을 제안하는 것이 아니라, 보스 레이드 NPC 행동을 실패 비용과 판단의 결정성에 따라 분류하여 두 제어기의 권한을 분리하고, 규칙 기반 제어가 강화학습 정책의 제어권에 개입하는 동안 발생하는 on-policy 표본 불일치를 가변 길이 준마르코프 전이로 처리하는 협동 NPC 학습 구조를 제안하였다. 자체 제작 보스 레이드 환경에서, 순수 강화학습이 약 30만 에피소드에도 확보하지 못한 기믹 수행을 규칙 계층이 결정론적으로 보장하는 가운데 행동의 78%는 학습 정책이 결정하였고, 2만 에피소드 학습으로 최종 난이도 승률 70.8%에 도달하여 규칙 기반 기준(64-75%)과 동등한 수준을 보였다. 이는 전체 행동의 제한된 비율(21.8%)에만 결정론적 제어가 개입하는 조건에서도 기믹 성공률(86.9%)이 유지되고, 나머지 일반 전투 판단은 역할별 학습 정책이 담당할 수 있음을 보여 준다. 미숙한 플레이어 모델과의 협동 승률이 학습에 따라 0%대에서 56%까지 개선된 결과는, 성향 랜덤화가 실제 플레이어와의 협동을 겨냥한 강건성으로 이어졌음을 시사한다. 남은 과제는 계획된 통제 비교와 제거 실험을 통해 표본 처리 방식의 기여를 분리 검증하고, 실제 플레이어 사용성 평가를 통해 제안 구조가 수치 성능을 넘어 신뢰할 수 있는 협동 파트너로 인식되는지를 확인하는 것이다.

참고문헌

- 김동주, 고석주. (2025a). FSM과 강화학습 기반의 지능형 NPC AI: 2D 모바일 자동 진행 RPG 게임의 구현 연구. *정보처리학회논문지*, 14(6), 480–488.
<https://doi.org/10.3745/TKIPS.2025.14.6.480>
- 김동주, 고석주. (2025b). 분산형 하이브리드 AI 기반 모바일 RPG NPC 시스템의 구현. *사물인터넷융복합논문지*, 11(6), 83–90.
<https://doi.org/10.20465/KIOTS.2025.11.6.083>
- 전준렬, 홍진혁. (2025). 보스 레이드 게임에서 인간 플레이 패턴 모방을 위한 강화학습 기반 접근법. *정보과학회 컴퓨팅의 실제 논문지*, 31(10), 463–468.
- Alshiekh, M., Bloem, R., Ehlers, R., Könighofer, B., Niekum, S., & Topcu, U. (2018). Safe reinforcement learning via shielding. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1), 2669–2678.
- Bengio, Y., Louradour, J., Collobert, R., & Weston, J. (2009). Curriculum learning. *Proceedings of the 26th International Conference on Machine Learning*, 41–48.
- Berner, C., Brockman, G., Chan, B., Cheung, V., Dębiak, P., Dennison, C., ... Zhang, S. (2019). Dota 2 with large scale deep reinforcement learning. *arXiv preprint arXiv:1912.06680*.
- Carroll, M., Shah, R., Ho, M. K., Griffiths, T., Seshia, S., Abbeel, P., & Dragan, A. (2019). On the utility of learning about humans for human-AI coordination. *Advances in Neural Information Processing Systems*, 32.
- Isla, D. (2005). Handling complexity in the Halo 2 AI. *Proceedings of the Game Developers Conference*.
- Jaderberg, M., Czarnecki, W. M., Dunning, I., Marris, L., Lever, G., Castañeda, A. G., ... Graepel, T. (2019). Human-level performance in 3D multiplayer games with population-based reinforcement learning. *Science*, 364(6443), 859–865.
- Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. (2017). Multi-agent actor-critic for mixed cooperative-competitive environments. *Advances in Neural Information Processing Systems*, 30.

- Malle, B. F., & Ullman, D. (2021). A multidimensional conception and measure of human-robot trust. In C. S. Nam & J. B. Lyons (Eds.), *Trust in human-robot interaction* (pp. 3–25). Academic Press.
- Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J., & Whiteson, S. (2018). QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning. *Proceedings of the 35th International Conference on Machine Learning*, 4295–4304.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- Sutton, R. S., Precup, D., & Singh, S. (1999). Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial Intelligence*, 112(1–2), 181–211.
- Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., & Abbeel, P. (2017). Domain randomization for transferring deep neural networks from simulation to the real world. *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 23–30.
- Vinyals, O., Babuschkin, I., Czarnecki, W. M., Mathieu, M., Dudzik, A., Chung, J., ... Silver, D. (2019). Grandmaster level in StarCraft II using multi-agent reinforcement learning. *Nature*, 575(7782), 350–354.
- Wang, T., Dong, H., Lesser, V., & Zhang, C. (2020). ROMA: Multi-agent reinforcement learning with emergent roles. *Proceedings of the 37th International Conference on Machine Learning*, 9876–9886.